



SIMMLB

MLB AI PREDICTION SYSTEM

팀 프로젝트 최종 발표 · 2026.05

MLB 승부예측 AI 시스템

머신러닝으로 홈팀 승리 확률을 예측하고, GPT-4o-mini가 한국어 분석 근거를 자동 생성하며, 경기 진행 중 실시간으로 승률 변동을 push하는 풀스택 AI 시스템.

팀

A팀 Data · B팀 ML · C팀
API/Front

기간

2026.04 – 05 ·
4주

스택

LightGBM · FastAPI · Next.js ·
GPT-4o

버전

v2.2 ·
final

발표 순서

01	왜 만들었나 예측 팬이 지금 겪는 3가지 불편	WHY
02	무엇을 만들었나 예측 → 근거(SHAP·LLM) → 라이브 승률	WHAT
03	실제 화면 데모 오늘 예측 · 분석 · 라이브 · 일정 · 순위	DEMO
04	어떻게 만들었나 아키텍처 · 기술 스택 · ERD · AI 파이프라인	HOW
05	모델 성능 & 일정 & R&R 트랙 레코드 · 4주 WBS · 팀별 담당 영역	RESULT

I. 왜 만들었나

스포츠 데이터는 넘쳐나지만, "오늘 이 경기 누가 이길까 — 그리고 왜?"에 근거를 가지고 답해주는 도구는 없었다.

예측 팬의 3가지 불편

01

흩어진 데이터

팀 성적, 선발 투수 스탯, Statcast, 날씨, 파크팩터가 제각각 다른 사이트에 흩어져 있다. 한 경기를 판단하려면 5–6개 소스를 직접 뒤져야 한다.

소스 5곳+ 수동 취합

02

근거 없는 픽

"오늘은 다저스" 같은 픽은 많지만 *왜* 그런지 설명이 없다. 어떤 지표가 결정적이었는지 알 수 없어 신뢰하기 어렵다.

설명 불가 블랙박스

03

멈춰있는 예측

경기 전 한 번 나온 예측은 경기가 시작되면 그대로 멈춘다. 7회 역전극이 벌어져도 승률은 업데이트되지 않는다.

경기 중 정적 상태

II. 무엇을 만들었나

예측에서 끝나지 않는다. 왜 이렇게 봤는지 — 경기가 흐르며 어떻게 바뀌는지까지.

승부예측을 완성하는 3단계 사이클

STEP 1 · PREDICT

예측한다

47개 피처를 LightGBM + XGBoost 앙상블에 넣어 경기별 홈팀 승률을 산출. Isotonic 보정으로 확률을 신뢰할 수 있게 만든다.

앙상블 AUC 0.564 · 신뢰도 배지



STEP 2 · EXPLAIN

설명한다

SHAP로 예측에 가장 크게 기여한 피처 TOP 5를 뽑고, GPT-4o-mini가 이를 근거로 한국어 분석 2-3문장을 자동 생성한다.

SHAP + LLM · 설명 가능 AI



STEP 3 · LIVE

추적한다

경기가 시작되면 30초마다 스코어를 폴링해 라이브 승률을 다시 계산하고, SSE로 변동(▲/▼)을 실시간 push한다.

실시간 SSE · ▲/▼ 변동

두 개의 예측 시점

같은 모델 위에서 경기 전과 경기 중, 두 가지 예측 경험을 제공한다.

🕒

PRE-GAME

사전 예측

경기 시작 전, 확정된 데이터만으로 산출한 기준 승률

시점	경기 T-15분 + 19:30 KST 일괄 폴백
입력	팀 성적 · 선발 투수 · 라인업 Statcast · 파크팩터
출력	홈/원정 승률 · 신뢰도 배지 · SHAP TOP 5
근거	GPT-4o-mini 한국어 분석 2-3문장

🏆

IN-GAME

라이브 예측

경기 진행 중, 실시간 스코어를 반영해 갱신되는 승률

시점	30초 주기 폴링 · 경기 종료 시 자동 정산
입력	이닝 · 점수 · 주루 · 아웃카운트 실시간
출력	라이브 승률 · 사전 대비 변동(▲/▼)
전송	SSE(EventSource)로 클라이언트 실시간 push

전체 기능 한눈에



오늘의 예측

당일 전 경기의 홈/원정 승률과 모델 픽을 카드로 제시, 오티 높은 순 정렬.

/predictions/today



경기 분석 · SHAP

SHAP 기여도 TOP 5 시각화 + GPT-4o-mini 한국어 분석 근거.

/games/{pk}



라이브 스코어

SSE 실시간 push로 이닝·점수와 승률 변동을 동시 표시.

/live/stream (SSE)



경기 일정

달력에 날짜별 적중률을 색상 dot으로, 예측 vs 결과를 √/X 채점.

/schedule



팀 순위표

AL/NL 디비전·와일드카드 순위를 한 앱에서 통합 제공.

/standings



모델 성능 · 나의 픽

공개 트랙 레코드(Brier·Accuracy)와 내 픽 적중률 추적.


/model · /me/picks

III. 실제 화면

완성된 서비스의 핵심 5개 화면을 차례로 살펴봅니다.

당일 전 경기 한눈에

-  **홈/원정 승률** 바와 모델 픽을 카드로 제시, **오티지** 높은 순 정렬
-  신뢰도 **HIGH / MED / LOW** 배지로 모델 확신도 표시
-  로그인 시 경기별 **나의 픽**을 저장하고 적중률 추적

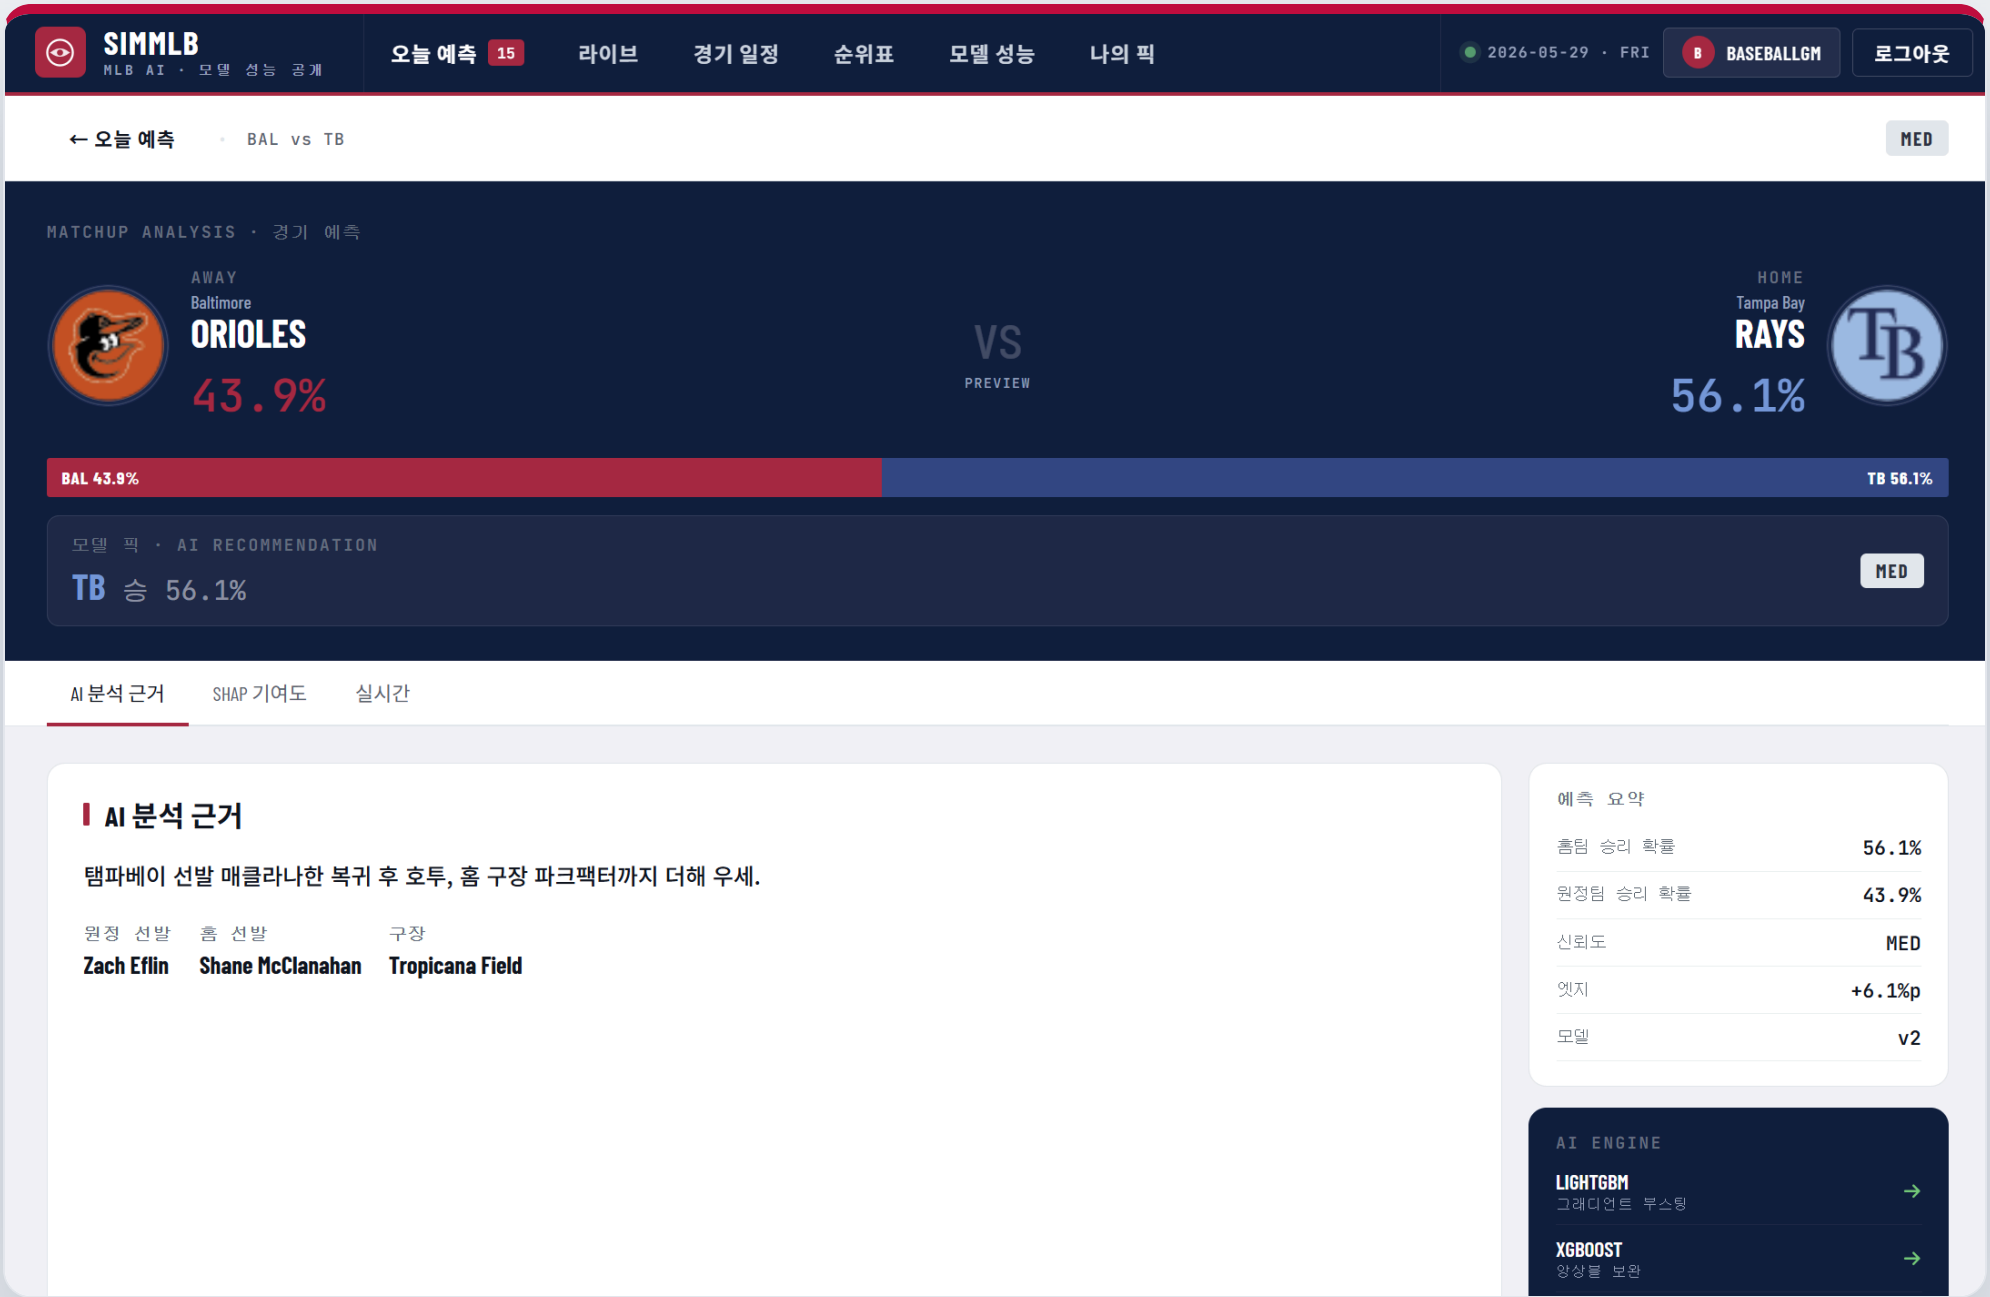


경기 분석 & SHAP

설명 가능 AI

왜 이렇게 예측했나

- AI GPT-4o-mini가 SHAP 상위 피처를 근거로 한국어 분석 생성
- ± SHAP 기여도 TOP 5를 좌우 바로 시각화 — HOME ↔ AWAY
- ⚡ 선발 투수 · 구장 정보와 실시간 탭까지 한 화면에 통합



경기 중 승률이 움직인다


 진행 중 / 예정 / 종료 그룹 헤더로 직관적 정리



날짜별 적중 기록

 경기별 예측 vs 실제 결과를 $\sqrt{X}$ 아이콘으로 즉석 채점

% 선택 날짜의 전체 적중률을 상단 KPI로 요약



팀 순위

통합 순위표

리그 판도 한 화면에

- # AL/NL 디비전별 순위와 승차·홈/원정·연속 기록 표시
- WC 와일드카드 진출권을 리그별 상위 3팀으로 자동 계산
- 30개 구단 실제 로고와 함께 직관적으로 시각화

SIMMLB
MLB AI · 모델 성능 공개

오늘 예측 15

라이브

경기 일정

순위표

모델 성능

나의 픽

2026-05-29 · FRI

BASEBALLGM

로그아웃

STANDINGS · 2026 MLB 시즌 순위표

팀 순위

AL 팀 15 TEAMS, NL 팀 15 TEAMS

리그

AL 리그

NL 리그

보기

디비전별

와일드카드

■ 디비전 1위 — 플레이오프 자동 진출, ■ 2-3위 — 와일드카드 진출권 (리그별 상위 3팀)

AL EAST · 동부지구

5팀

#	팀	W	L	PCT	GB	HOME	AWAY	L10	연속
1	 TOR Toronto Blue Jays	35	21	0.625	-	19-9	16-12	7-3	W3
2	 NYY New York Yankees	33	23	0.589	2.0	18-10	15-13	6-4	L1
3	 BAL Baltimore Orioles	30	26	0.536	5.0	16-12	14-14	5-5	W1
4	 TB Tampa Bay Rays	28	28	0.500	7.0	15-13	13-15	6-4	W2
5	 BOS Boston Red Sox	26	30	0.464	9.0	14-15	12-15	4-6	L2

AL CENTRAL · 중부지구

5팀

#	팀	W	L	PCT	GB	HOME	AWAY	L10	연속
1	 DET Detroit Tigers	36	20	0.643	-	20-8	16-12	8-2	W4

IV. 어떻게 만들었나

3개 팀이 병렬로, 수집 → 피쳐 → 모델 → API → 프론트를 4주에 통합했다.

시스템 아키텍처

COLLECTOR · [A팀]

데이터 수집기

MLB StatsAPI · Statcast · FanGraphs · Open-Meteo

매일 07:00 일정·로스터·스탯 수집 · APScheduler 스케줄링

▼ 수집 · 적재 (Alembic 마이그레이션) ▼

SERVING · [C팀]

FASTAPI

Port 8000 · /predictions · /games · /live(SSE)

추론 서비스 · 예측 API · SSE 실시간 push

CACHE

REDIS 7

TTL 1h · SSE 채널

예측 결과 캐시 · 라이브 pub/sub

STORAGE · [A팀]

POSTGRESQL 16

11 tables · 파티셔닝

팀·선수·경기·예측 영구 저장

▼ HTTP · EventSource ▼

CLIENT · [C팀]

NEXT.JS 14

Vercel 배포 · TypeScript

오늘 예측 · 라이브 · 일정 · 순위 · 모델 성능 6개 화면

배 포 백엔드 **Render** 무료 티어(예측은 스케줄 기반이라 Sleep 허용) · 프론트 **Vercel** · 알림 **Discord webhook**

기술 스택

ML · [B팀]

머신러닝

LightGBM	4.3+
XGBoost	2.0+
scikit-learn	Isotonic
Optuna	tuning
SHAP	설명

DATA · [A팀]

데이터

pybaseball	–
MLB Stats API	–
Statcast	savant
FanGraphs	–
Open-Meteo	weather

BACKEND · [A/C팀]

백엔드

FastAPI	0.110+
PostgreSQL	16
Redis	7 · SSE
SQLAlchemy	2.0
APScheduler	cron

FRONTEND · [C팀]

프론트엔드

Next.js	14
TypeScript	–
EventSource	SSE
Barlow Cond.	type
Noto Sans KR	type

LLM

GPT-4O-MINI

배포 · 백엔드

RENDER

배포 · 프론트

VERCEL

핵심 ERD

teams를 중심으로 games·players가 연결되고, 모든 예측은 game_predictions에 누적된다

teams		팀
PK	mlbam_team_id	INT
	name	VARCHAR
	abbreviation	VARCHAR
	league · division	VARCHAR

players		선수
PK	player_id	BIGINT
	full_name	VARCHAR
	throws · bats	CHAR
FK	current_team_id	→ teams

games		경기
PK	game_pk	BIGINT
FK	home_team_id	→ teams
FK	away_team_id	→ teams
FK	home/away_starter	→ players
	status · score	SMALLINT

team_daily_snapshots		시점 스냅샷
PK	team_id	복합
PK	snapshot_date	복합
	wins · losses	SMALLINT
	rest_days	SMALLINT

game_lineups		라인업
PK·FK	game_pk	→ games
PK·FK	player_id	→ players
	batting_order	SMALLINT
	confirmed_at	TS

game_predictions		예측 결과
PK	id	BIGSERIAL
FK	game_pk	→ games
	home_win_prob	NUMERIC
	shap_top5	JSONB
	reasoning_text	TEXT
	is_correct	BOOL

AI 예측·근거 파이프라인

피처 추출 → 앙상블 추론 → 확률 보정 → SHAP → LLM 근거까지 한 흐름으로 묶었다.

STEP 01

피처 추출

game_datetime 이전 데이터만으로 47개 피처 생성. 데이터 누수 차단(as_of_date 강제).

```
build_features()
```

STEP 02

앙상블 추론

LightGBM·XGBoost 개별 예측을 역 logloss softmax 가중으로 결합.

```
LGBM + XGB
```

STEP 03

확률 보정

Isotonic Regression으로 예측 확률을 단조 보정해 신뢰도 배지 분류.

```
IsotonicRegression
```

STEP 04

SHAP + LLM

SHAP TOP 5 추출 → 프롬프트 빌드 → GPT-4o-mini가 한국어 근거 생성.

```
SHAP · GPT-4o-mini
```

```
// game_predictions 저장 예시
{ "home_win_prob": 0.628, "confidence_level": "HIGH", "shap_top5": ["fip_diff", "roll_win_diff", "bat_ev_diff"],
  "reasoning_text": "홈팀 선발의 FIP가 우수하고 최근 20경기 승률이 리그 최고 수준..." }
```

모델 성능 검증

v1 → v2.2로 데이터·피처를 확장하며 모든 지표가 개선됐다.

LIGHTGBM AUC

0.5263 → **0.5750**

▲ +4.87%p

양상불+캘 AUC

0.5336 → **0.5640**

▲ +3.04%p

학습 데이터

4,912 → **8,082**

▲ +65%

피처 수

29 → **47**

▲ +18 features

신뢰도 구간별 정확도

CONFIDENCE BANDS · 트랙 레코드

HIGH · 60%+

66.0%

MED · 55%+

55.4%

LOW · ~50%

49.1%

MLB는 본질적으로 고노이즈 도메인(흙 실제 승률 ~52%). 목표 Brier < 0.23 · Accuracy > 0.55 달성, 신뢰도가 높을수록 정확도가 단조 상승.

THANK YOU · 감사합니다

예측을 넘어, 근거와 실시간으로

"누가 이길까 — 왜 그런가 — 지금은 어떻게 바뀌었나." SimMLB는 데이터가 쌓일수록 더 똑똑해집니다.

A팀 · DATA

수집 · DB · 스케줄러 · 배포

B팀 · ML

피처 · 모델 · SHAP · LLM

C팀 · API/Front

FastAPI · Next.js · 실시간



SIMMLB
MLB AI · v2.2