



SIMMLB

MLB AI PREDICTION SYSTEM · v2.2

프로젝트 최종 소개 · 2026.05

MLB 승부예측 AI 시스템

머신러닝으로 홈팀 승리 확률을 예측하고, GPT-4o-mini가 한국어 분석 근거를 자동 생성하며,
경기 진행 중 실시간으로 승률 변동을 push하는 풀스택 AI 시스템

47

피쳐 / FEATURES

8,082

학습 경기 / GAMES

0.564

앙상블 AUC

30s

라이브 SSE 주기

프로젝트 개요

SimMLB는 MLB 정규시즌 경기의 **홈팀 승리 확률**을 머신러닝으로 예측하는 **엔드-투-엔드 AI 시스템**입니다. 데이터 수집부터 추론, 근거 생성, 실시간 push까지 전 과정을 자동화했습니다.

- 1 자동 데이터 수집 — 스텔스 스크래퍼 + MLB StatsAPI + Statcast로 매일 갱신
- 2 47개 피처 → 앙상블 모델로 경기별 홈팀 승률 추론
- 3 SHAP + GPT-4o-mini가 한국어 분석 근거 2-3문장 자동 생성
- 4 라이브 승률 push — 경기 중 SSE로 실시간 변동(▲/▼) 표시

예측 대상

홈팀 승률

당일 경기 + 경기 진행 중 라이브 승률

학습 데이터

8,082 경기

2023-2026 시즌 통합 (v1 대비 +65%)

예측 주기

T-15_{min}

경기별 개별 추론 + 19:30 KST 일괄 폴백

시스템 파이프라인

01 · COLLECT

데이터 수집

- BBref 스텔스 스크래퍼 (팀 · dWAR)
- MLB Live Feed 날씨 · 라인업 · 선발
- Statcast 투구 단위 데이터
- FanGraphs · Open-Meteo

02 · FEATURE

피처 엔지니어링

- 47개 피처 생성
- 라인업 9명 Statcast 평균
- 선발 velo · spin · whiff
- 휴식일 · dWAR · 파크팩터

03 · MODEL

ML 추론

- LightGBM + XGBoost 앙상블
- 역 logloss 가중 결합
- Isotonic 확률 보정
- Optuna 100 trials 튜닝

04 · EXPLAIN

근거 생성

- SHAP 상위 5개 피처 추출
- 프롬프트 빌더 구성
- GPT-4o-mini 한국어 2-3문장
- 신뢰도 배지 HIGH/MED/LOW


05 · LIVE

실시간 PUSH

- 30초 라이브 폴러
- 라이브 승률 조정
- SSE 실시간 push (▲/▼)
- Final 시 자동 postgame

당일 전 경기 한눈에

-  홈/원정 승률 바와 모델 픽을 카드로 제시, **오티지 높은 순 정렬**
-  신뢰도 **HIGH / MED / LOW** 배지로 모델 확신도 표시
-  로그인 시 경기별 **나의 픽**을 직접 저장하고 적중률 추적




경기 분석 & SHAP

설명 가능 AI

왜 이렇게 예측했나

- AI GPT-4o-mini가 SHAP 상위 피처를 근거로 한국어 분석을 생성
- SHAP 기여도 TOP 5를 좌우 바로 시각화 — HOME ↔ AWAY 방향성
- 선발 투수 · 구장 정보와 실시간 탭까지 한 화면에 통합




경기 중 승률이 움직인다

 **SSE 실시간 push** — 타석 결과마다 승률 변동 ▲+1.5%p / ▼-2.1%p


9 이닝·점수·주루·아웃카운트와 사전 예측 대비 총 변동 표시

 진행 중 / 예정 / 종료 그룹 헤더로 직관적 정리



날짜별 예측 트랙 레코드

- ✓ 달력에 날짜별 적중률을 색상 dot으로 — 과거 기록 열람 통합
- X 경기별 예측 vs 실제 결과를 ✓/X 아이콘으로 즉석 채점
- # AL/NL 디비전·와일드카드 순위표까지 한 앱에서 제공



ML 모델 & 성능

LIGHTGBM AUC

0.5263 → **0.5750**
▲ +4.87%p

양상블+캘 AUC

0.5336 → **0.5640**
▲ +3.04%p

학습 데이터


4,912 → **8,082**
▲ +65%

피처 수

29 → **47**
▲ +18 features

신뢰도 구간별 정확도

최근 트랙 레코드 · CONFIDENCE BANDS



MLB 경기 결과는 본질적으로 고노이즈 도메인 (홈팀 실제 승률 ~52%). AUC 0.56+는 도메인 한계 근처의 의미 있는 엷지이며, 모델 픽은 신뢰도가 높을수록 정확도가 단조 상승.

피처 엔지니어링

수	피 처 그룹	출 처
15	팀 투구 · 타격 ERA · FIP · WHIP · OPS · OBP · SLG	BBref CSV
8	선발 투수 Statcast v2 구속 · 회전수 · 헛스윙% · ERA	Statcast
6	라인업 9명 Statcast v2 타구속도 · 발사각 · Hard-hit%	Statcast
3	팀 롤링 승률 최근 20경기 윈도우 · 데이터 누수 방지	DB games
2	휴식일 v2 홈/원정 1-5일 클램프	DB games
3	구장 · dWAR Run Factor · HR Factor · 돔 여부	park / BBref

총 피 처 수

47개

v1 대비 +18개 확장 — 라인업·선발 개별 Statcast가 핵심 개선

데 이 터 누 수 방 지

경기 데이터만 사용. BBref 시즌 통계는 기존 적용으로 look-ahead bias 차단

라 인 업 폴 백

Statcast 매칭 0명이면 팀 평균, 1명 이상이면 매칭 선수 평균으로 자동 대체

ML

머신러닝

LightGBM 4.3+

XGBoost 2.0+

scikit-learn Isotonic

Optuna 100 trials

SHAP 설명

DATA

데이터

pybaseball

MLB Stats API

Baseball Ref

Statcast

Open-Meteo

BACKEND

백엔드

FastAPI 0.110+

PostgreSQL 16

Redis 7 · SSE

SQLAlchemy 2.0

APScheduler

FRONTEND

프론트엔드

Next.js 14

TypeScript

EventSource SSE

Barlow Cond.

Noto Sans KR

LLM

GPT-4o-MINI

배포 · 백엔드

RENDER

배포 · 프론트

VERCEL

NEXT STEPS · 향후 과제

데이터가 쌓일수록 더 똑똑해진다

★★★★

라인업 30일 윈도우 Statcast —
game_date 기준 시점별 집계

★★

선발 vs 라인업 L/R 핸드 매치업 ·
FanGraphs xwOBA

★★★★

시즌 누적 재학습 — 2027+ 데이터 자동
축적 후 성능 향상



SIMMLB

MLB AI PREDICTION SYSTEM · v2.2